Grammaires et Analyse Syntaxique - Cours 6 Introduction à l'analyse ascendante

Ralf Treinen





treinen@irif.fr

10 mars 2022

© Ralf Treinen 2020–2022

Analyse descendante

- Nous avons vu au cours 4 et 5 une méthode d'analyse descendante (angl. : top-down, ou dans le contexte de l'analyse grammaticale recursive descent) :
- L'analyse descendante construit l'arbre de dérivation commençant par la racine, et puis en ajoute dans l'arbre des enfants dans un ordre descendant et de gauche à droite.
- L'analyse descendante correspond à la construction d'une dérivation gauche.
- Cette dérivation gauche est construite dans l'ordre naturel : on commence avec l'axiome, et on termine sur le mot d'entrée.
- On a assez peu d'information pour guider la construction : Le non-terminal courant, et le symbole suivant de l'entrée.

Analyse descendante : avantages et inconvénients

- Avantage : facile à implémenter à la main quand la grammaire est LL(1).
- ► Inconvénient : peut nécessiter des contorsions de la grammaire quand la grammaire n'est pas LL(1).
- Des modifications de la grammaire (comme élimination de la récurrence gauche) bousculent la structure de l'arbre de dérivation.
- Un changement fondamental de la grammaire est gênant car on s'intéresse à la fin aussi à la structure trouvée par l'analyse (l'arbre de dérivation) qui maintenant ne correspond plus à la grammaire initiale.

Analyse ascendante

- L'alternative à l'analyse descendante est l'analyse ascendante (angl. : bottom-up) :
- L'analyse ascendante construit l'arbre de dérivation en commençant par les feuilles, et en faisant grandir l'arbre par combinant des arbres existants par des nouveaux nœuds.
- Ça correspond à quel type de dérivation? Voir la suite!
- Nous avons maintenant beaucoup plus d'informations pour guider la construction de l'arbre : on a déjà des arbres de dérivations qu'il suffit de combiner.
- Pour cette raison l'analyse ascendante peut être plus puissante que l'analyse descendante.

Analyse descendante vs. analyse ascendante

► Exemple : la grammaire

$$E \rightarrow (E+E) \mid (E*E) \mid i$$

- Quand l'analyse descendante voit le symbole (, elle ne saura pas quelle production appliquer.
- Nous avons vu au cours 4 que cette grammaire n'est pas LL(1).
- Quand l'analyse ascendante voit que des parties de l'entrée sont reconnues comme étant des (, E, +, E,), elle sait que ça correspond à la première production, et elle va combiner ces 5 arbres par un nouveau nœud E.

Analyse ascendante

- Elle lit l'entrée de gauche à droite.
- Le principe est que des parties de l'entrée sont combinées en un morceau d'arbre de dérivation dès que possible.
- Structures de donnée de l'analyseur ascendant :
 - le reste de l'entrée qui reste à consommer
 - une pile de symboles de ∑ ∪ N. Elle contient la partie de l'entrée qu'on a déjà consommé.
- Toutes les réductions (applications d'une règle dans le sens ascendant) se font sur la partie haute de la pile.
- Un non-terminal sur la pile est en vérité la racine d'un morceau d'arbre de dérivation.


Pile et Entrée pendant l'analyse ascendante

```
R\`{e}gles:S\rightarrow E~\$~E\rightarrow E+T~|~T~T\rightarrow T*F~|~F\rightarrow (~E~)~|~i
```

Partie de l'entrée déjà lue : i+i

Reste à lire : *i\$

pile (sommet à droite) : entrée :





Actions dans l'analyse ascendante

- Il a quatre types d'action :
 - shift : transférer le symbole suivant de l'entrée sur le sommet de la pile;
 - ▶ **reduce** $N \to \alpha$: remplacer une séquence α qui se trouve en haut de la pile par un N, quand N $\to \alpha$ est une règle de la grammaire;
 - accepter;
 - signaler une erreur.
- ➤ On parle aussi de shift-reduce parser car shift et reduce sont les actions essentielles.

Shift

Situation de départ :

pile (sommet à droite) :

 entrée :

 a_1 a_2 a_3 a_4

Situation après un shift :

pile (sommet à droite) :

 x_1 x_2 x_3 a_1

entrée :

 $a_2 \mid a_3 \mid a_4$

Reduce

Situation de départ :

pile (sommet à droite) :

<i>x</i> ₁	<i>x</i> ₂	<i>y</i> ₁	y 2	<i>y</i> ₃
-----------------------	-----------------------	-----------------------	------------	-----------------------

entrée :

 $a_1 \mid a_2 \mid a_3$

Situation après un reduce $N \rightarrow y_1y_2y_3$:

pile (sommet à droite) :

$$x_1 x_2 N$$

entrée :

$$\begin{vmatrix} a_1 & a_2 & a_3 \end{vmatrix}$$

Exemple

La grammaire $G_1 = (\{i, +, *, (,), \$\}, \{S, E, T, F\}, S, P)$, où P est

- ► Cette grammaire engendre les expressions arithmétiques avec + et *, en prenant en compte la priorité de * sur +, et l'associativité à gauche de + et de *.
- Nous avons vu au cours 5 que cette grammaire n'est pas LL(1), à cause de la récurrence gauche.

Exemple: actions du parseur

► Règles de la grammaire :

$$S \rightarrow E \$ \quad E \rightarrow E + T \mid T \quad T \rightarrow T * F \mid F \quad F \rightarrow (\ E\) \mid \texttt{i}$$

Actions : s (shift), r (reduce), a (accept)

pile	entrée	action	pile	entrée	action
	i+i*i\$	S	E+T	*i\$	S
i	+i*i\$	$r \; F o \mathtt{i}$	E+T*	i\$	S
F	+i*i\$	$r T \to F$	E+T*i	\$	$r F o \mathtt{i}$
T	+i*i\$	$r \to T$	E+T*F	\$	$r T \to T * F$
Е	+i*i\$	S	E+T	\$	$r \to E + T$
E+	i*i\$	s	Е	\$	S
E+i	*i\$	$r \; F o \mathtt{i}$	E\$		$r S \rightarrow E$ \$
E+F	*i\$	$r T \to F$	S		a

Exemple : quelle est la dérivation produite?


On regarde la suite des reductions sur la concaténation de pile et entrée :

```
i+i*i$ - F+i*i$ - T+i*i$ - E+i*i$ - E+F*i$ - E+T*i$ - E+T*F$ - E+T$ - E+T$
```

Inverser l'ordre de cette séquence :

- C'est une dérivation droite!
- ▶ Donc, la parseur shift-reduce construit une dérivation droite dans un ordre inversé.
- Regardons cela maintenant avec construction de l'arbre de dérivation.

S \rightarrow E \$ E \rightarrow E + T | T T \rightarrow T * F | F F \rightarrow (E) | i Entrée complète : i+i*i\$ Situation initiale Après Shift Après Reduce F \rightarrow i Après Reduce T \rightarrow F Après Reduce E \rightarrow T Après Shift Après Shift Après Reduce F \rightarrow i Après Reduce T \rightarrow F Après Shift Après Shift Après Reduce F \rightarrow i Après Reduce T \rightarrow T * F Après Reduce E \rightarrow E + T Après Shift Après Reduce S \rightarrow E \$



Efficacité

- Pour appliquer une opération de reduce $N \to \alpha$ il faut chercher une occurrence de α .
- L'intérêt de la construction d'une dérivation droite construite à l'envers est qu'il suffit de chercher α dans la pile.
- ► En plus, si on réussit à éviter des *shift* prématurés, il suffit de regarder seulement le haut de la pile!


Grammaires et Analyse Syntaxique - Cours 6 Introduction à l'analyse ascendante ∟Analyse ascendante

Prendre fausse route


- ► Attention le parseur peut a priori aussi prendre une fausse route.
- ▶ Dans une situation où il y a en haut de la pile α et N → α est une règle :
 - ▶ On peut faire un **reduce** $N \rightarrow \alpha$, ou un **shift**
 - Quand il y une autre règle $M \to \beta$, et β est également en haut de la pile (c'est possible quand α est un suffixe de β ou l'inverse) :
 - on peut faire **reduce** $N \to \alpha$ ou **reduce** $M \to \beta$
- Comment éviter que notre parseur prenne fausse route?

Deux Reduce possibles





1. Soit reduce $N \rightarrow y_1y_2y_3$:




2. Soit reduce $M \rightarrow y_2y_3$:

<i>x</i> ₁	<i>x</i> ₂	<i>y</i> ₁	М
-----------------------	-----------------------	-----------------------	---

Exemple 1 : un shift prématuré

$$S \rightarrow E ~\$~~ E \rightarrow E + T \mid T~~ T \rightarrow T * F \mid F~~ F \rightarrow (~E~) \mid i$$



Le problème dans l'exemple 1

- Dans l'exemple 1 on a obtenu en haut de la pile : T +
- Même si ce qui suit dans l'entrée se réduit vers T on aura en haut de la pile : T + T
- ightharpoonup On a bien S ightharpoonup E+T ightharpoonup T+T
- ► Mais ce n'est **pas** une dérivation droite!
- ► On fait on n'a **pas** que $S \stackrel{d}{\rightarrow} {}^* T+T$
- On aurait du réduire le premier T à E avant de shifter le +

Exemple 2 : un reduce prématuré


$$S \rightarrow E ~\$~~ E \rightarrow E + T ~|~ T ~~ T \rightarrow T * F ~|~ F ~~ \uparrow G ~~ (~E~) ~|~ i$$

Le problème dans l'exemple 2

- Dans l'exemple 2 on a obtenu en haut de la pile : E + E
- Or, E+ se réduit seulement si on a après un T.
- Peut importe le mot $w \in \Sigma^*$ qu'on trouve après, on ne peut pas avoir que $Ew \to^* T$.
- ▶ On n'aurait pas du réduire le deuxième T à E mais shifter le *.

Exemple 3 : mauvais choix de la règle dans une réduction

$$S \rightarrow E \$ \quad E \rightarrow E + T \mid T \quad T \rightarrow T * F \mid F \quad F \rightarrow (\ E\) \mid \mathtt{i}$$



Le problème dans l'exemple 3

- Dans l'exemple 3 on a obtenu en haut de la pile : T * T
- ▶ Or, T* se réduit seulement si on a après un F.
- Peut importe le mot $w \in \Sigma^*$ qu'on trouve après, on ne peut pas avoir que $Tw \to^* F$.
- ▶ On n'aurait pas du réduire par la règle $T \rightarrow F$ mais réduire par la règle $T \rightarrow T*F$.

Éviter la mauvaise route

- Nous avons vu que notre analyseur ascendant peut prendre mauvaise route.
- Nous allons maintenant caractériser ce que ça veut dire mauvaise route.
- Une fois qu'on a trouvé et compris cette caractérisation on cherche un moyen pour détecter efficacement le cas de mauvaise route (la semaine prochaine).
- Quand on sait comment détecter les mauvais cas on verra aussi comment les éviter dans l'analyse ascendante.

Comment caractériser les cas de mauvaise route

Définition

 $\alpha \in (\Sigma \cup N)^*$ est *préfixe réductible* ssi

- ightharpoonup il y a une décomposition $lpha=lpha_1lpha_2$
- ightharpoonup et une règle $N \to \alpha_2$
- ightharpoonup et un mot $w \in \Sigma^*$ tel que

C'est à dire

- Si α est un préfixe réductible, il y encore de l'espoir : on peut encore avoir une continuation w de l'entrée tel que αw fait partie d'une dérivation droite. w peut être vide.
- Mais ce n'est pas un préfixe quelconque : α se termine précisément avec le résultat de la dernière application de règle.

Comment caractériser les cas de mauvaise route

- Cette notion de préfixe réductible nous sert à distinguer les bonnes et mauvaises routes :
 - Si le contenu de la pile est un préfixe réductible alors on peut faire une opération reduce sans de naviguer dans une impasse.
 - Si le contenu de la pile n'est pas un préfixe réductible alors il faut qu'on puisse atteindre par des opérations shift un préfixe réductible.
- ▶ Regardons cette notion de préfixe réductible sur les exemples que nous avons vu.

L'exemple du mauvais choix de règle

$$S \rightarrow E \$ \quad E \rightarrow E + T \mid T \quad T \rightarrow T * F \mid F \quad F \rightarrow (\ E\) \mid i$$

- ► On avait obtenu la pile : E+T*T
- ▶ Or il n'y aucun mot $w \in \Sigma^*$ tel que $S \stackrel{d}{\rightarrow} {}^*$ E+T*Tw
- Comment s'en convaincre? On peut essayer toutes les possibilités, ou on utilise la méthode que nous verrons la semaine prochaine.
- On aurait pas du réduire le F à T mais plutôt T*F à T car E+T est un préfixe réductible.

Exemples de mots qui sont des préfixes réductibles

► Rappel de la grammaire :

$$S \rightarrow E \$ \quad E \rightarrow E + T \mid T \quad T \rightarrow T * F \mid F \quad F \rightarrow (E) \mid \mathtt{i}$$

- ► E+T, car $S \xrightarrow{d} E\$ \xrightarrow{d} E+T\$$. Donc. w = \$.
- ► E+i, car $S \xrightarrow{d} E\$\xrightarrow{d} E+T\$\xrightarrow{d} E+F\$\xrightarrow{d} E+i\$$. Donc, w=\$.
- ► (T, car $S \xrightarrow{d} E\$ \xrightarrow{d} T\$ \xrightarrow{d} F\$ \xrightarrow{d} (E)\$ \xrightarrow{d} (T)\$$. Donc, w =)\$.
- ▶ E\$, car $S \stackrel{d}{\rightarrow}$ E\$. Donc $w = \epsilon$.

Préfixes réductibles et préfixes viables

- Attention quand vous regardez des autres cours/livres :
- Souvent l'explication de l'analyse shift-reduce est basée sur une autre notation, celle d'un préfixe viable.
- ► La différence entre les deux notions est qu'un préfixe viable est un préfixe quelconque d'un préfixe réductible.
- ▶ Dans ce cours nous utilisons la notion d'un préfixe réductible qui est plus simple.

La grande question qui reste

- lacktriangle Comment savoir si un lpha est un préfixe réductible ou pas?
- Ça semble compliqué : ne faut-il pas trouver la bonne continuation w et la complétion de l'arbre de dérivation pour αw? N'est ce pas encore plus difficile que notre problème de départ?
- La grande surprise est : non! On peut décider si α est un préfixe réductible en temps **linéaire** dans la longueur de α .
- Les automates du L2 nous viennent à la rescousse : on verra la semaine prochaine la construction d'un automate qui reconnaît les préfixes réductibles.

Comment est-ce possible?

- ► Regardons un exemple très simple.
- Grammaire $G_2 = (\{a,b\}, \{S\}, S, \{S \rightarrow aSb \mid \epsilon\})$
- $\mathcal{L}(G_2) = \{a^n b^n \mid n \ge 0\}$: pas reconnaissable.
- ► $L' = \{\alpha \in \{a, b, S\}^* \mid S \xrightarrow{d}^* \alpha\} = \{a^n b^n \mid n \ge 0\} \cup \{a^n S b^n \mid n \ge 0\}$: pas reconnaissable.
- ▶ Les préfixes de L' : $\{a^nb^m \mid m \le n\} \cup \{a^nSb^m \mid m \le n\}$: toujours pas reconnaissable.
- ► Comment est il possible que le langage des préfixes réductibles est reconnaissable ?

Comment est-ce possible?

- Il faut se rappeler ce que c'est un préfixe réductible!
- ► Un préfixe réductible est une séquence dans L' qui se termine sur le résultat d'une application d'une règle.
- Regardons une dérivation, les préfixes réductibles soulignés :

$$\mathsf{S} \to \underline{\mathtt{aSb}} \to \underline{\mathtt{aaSb}}\mathtt{b} \to \underline{\mathtt{aaaSb}}\mathtt{bbb} \to \underline{\mathtt{aaaaSb}}\mathtt{bbb} \to \underline{\mathtt{aaaa}}\mathtt{bbbb}$$

Donc, l'ensemble des préfixes réductibles est

$$\{\mathbf{a}^n\mathsf{Sb}\mid n\geq 1\}\cup \{\mathbf{a}^n\mid n\geq 0\}$$

et cet ensemble est reconnaissable! L'expression rationnelle est $a^*(aSb \mid \epsilon)$