Extraction d'information et indexation de documents

Damien Nouvel




Plan

1. Représenter des documents

2. Rechercher dans des documents

Approches pour la représentation

Top-down



Bottom-up

Indexs et documents

- Index
 - Doigt
 - Ouvrages censurés (XVIème, index librorum prohibitorum)
 - Liste alphabétique de termes
 - ⇒ Référence, pointeur
 - ⇒ Triangle sémiotique [Ogden & Richards 1923]
- Objectif: accès rapide au contenu
 - Du corpus (bibliothèque) vers les documents
 - Depuis un document vers une partie de son contenu

Décomposition du document

- ▶ Métadonnées : auteur, date, liens, etc.
- Document comme aggrégats
 - Chapitres, sections, sous-sections ...
 - Paragraphes
 - Phrases
 - Mots
 - Caractères, glyphes
- Segmentation selon des critères explicites ou implicites
 - Disposition du contenu (chapitres, paragraphes)
 - ⇒ Méta-information pour le document numérique
 - ⇒ Explicite, mais pas toujours renseignée
 - Contenu lui-même (phrases, mots)
 - ⇒ Selon la séquence des caractères
 - ⇒ Peu explicite, mais calculable
 - ⇒ Utilisation des espaces et ponctuations

Représentation des documents

- ⇒ Documents comme séquences de caractères
 - ▶ Manipulation aisée ... mais pas de sens
 - ▶ Unité minimale **sémantique** : le **mot**
 - Ou : mot-forme, lemme, lexème, token, morphème ...
 - Lien entre forme et sens
 - Attention aux expressions polylexicales (locutions)
 - \Rightarrow Segmentation
- ⇒ Documents comme séquences de mots
 - ▶ Problèmes de la **séquence**
 - Quel intérêt (position dans un document)
 - Combinatoire des séquences
- ⇒ Documents comme ensembles de mots
- \Rightarrow Sacs de mots
- ⇒ « Normaliser » les mots

Plan

1. Représenter des documents

2. Rechercher dans des documents

Matrice termes / documents

- ▶ Représentation à l'aide de matrices (tableaux)
 - Lignes : documents
 - Colonnes : termes (mots)
 - Cellules : occurrences d'un terme dans un document
 - ⇒ Matrice terms par documents
 - \Rightarrow Vector Space Model
- ⇒ Représentation mathématique, opérations algébriques
 - ► Exemple (sport vs politique)

	foot.	basket.	ballon	gouv.	ministre	aller
Euro 2016	3	0	2	0	0	3
Tony Parker	0	3	1	1	0	5
Présidentielles 2017	0	0	0	4	3	1
COP21	0	0	1	5	2	4
Affaire Blatter	5	0	0	2	1	7

Exploitation de la matrice

- ► Transformation de matrice (booléen, stopwords, TF.IDF, LSA)
- ▶ Mesures de distance / similarité (euclide, cosinus)
- Applications
 - Clustering: comparer les documents deux-à-deux, grouper
 - Classification : comparer les documents aux catégories
 - Indexation : comparer des mots-clés aux documents
- ▶ Problèmes linguistiques incontournables
 - Sémantique et dispersion des termes
 - Expressions polylexicales (locutions, colocations)
 - Synonymes, couverture et cohérence sémantique
 - Homonymes : prétraitement pour désambiguisation de sens

Applications et évaluation

- Applications
 - Moteurs de recherche
 - ⇒ Google, Bing, Yahoo, Qwant, Baidu, Yandex, Naver...
 - Similarités entre bases documentaires
 - Textométrie (calcul de spécificités)
- Évaluations (pertinence pour une recherche)
 - **Précision** : les documents sont-ils corrects ? (bruit)
 - Rappel: y-a-t-il tous les documents? (silence)
 - F-mesure : moyenne harmonique des deux précédents
 - Courbe rappel / précision
 - Précision moyenne (interpolée)
- ⇒ Problème de la **temporalité** (infos d'actualité vs atemporel)