Traduction automatique et assistée

Damien Nouvel

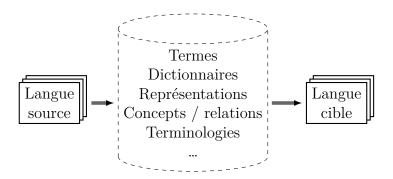


Plan

1. Automatiser la traduction

- 2. Traduction automatique
- 3. Traduction assistée

Modèle pour la traduction



Historique

- Quelques dates clé
 - ≈ 1799 : Pierre de Rosette
 - ≈ 1930 : Machine de Trojanski
 - ≈ 1946 : Traduction électronique (UK)
 - ≈ 1960 : Triangle de Vauquois
 - ≈ 1970 : Systran
 - $\approx 1980 : EUROTRA$
 - ≈ 1985 : Reverso (Softissimo)
 - ≈ 2000 : Corpus Europarl
 - ≈ 2004 : Google translation service
 - ≈ 2004 : OpenSubtitles (OPUS)
 - ≈ 2010 : Linguee
 - $\approx 2017 : \text{DeepL}$

Complexités de la traduction

- ▶ Diachronie : langues / dialectes / variantes
- Deux dimensions de difficultés
 - Trouver des correspondances entre termes (paradigmes)
 - Homonymes / synonymes
 - Tournures et emplois
 - Entités nommées (translittération)
 - Constructions (syntagmes)
 - Syntagmes / expressions polylexicales
 - Constructions syntaxiques
 - Prise en compte de la pragmatique (discours)?
- ▶ Deux méthodes informatisées pour la traduction
 - Traduction automatique et post-édition
 - Traduction assistée (mémoires de traduction)
 - ⇒ Degré d'intervention humaine

Les approches

- ▶ Selon le **domaine**
 - Vocabulaire contrôlé (météo, transports, etc.)
 - Langue générale
 - Langue de spécialité (terminologie)
- ▶ Selon la **méthode** de traduction
 - Paires de langues ($\approx 150^2 = 22K$)
 - Langue pivot (carré : $\approx 150 * 2 = 300$)
- Des corpus comme ressources
 - Parallèles : alignement des phrases (bitext)
 - Comparables : alignement des sections / documents

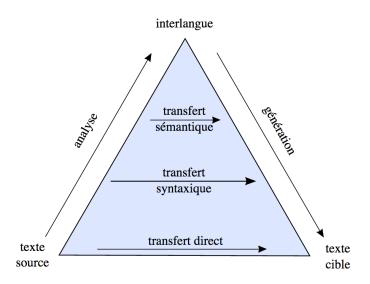
Plan

1. Automatiser la traduction

2. Traduction automatique

3. Traduction assistée

Triangle de Vauquois



Traduire segment à segment

- ▶ Impossible de tenir compte de tout le texte ...
- ⇒ Il faut **segmenter** / structurer
 - Énoncés
 - Propositions
 - Syntagmes
 - Mots
- ⇒ Meilleure hypothèse de traduction par recherche de segments
- ⇒ Difficultés avec les **dépendances** (accords, anaphores, etc.)

Exploitation de ressources

- ► Chaque ressource a ses avantages et inconvénients
 - Lexiques bilingues
 - ⇒ Traduction mot-à-mot et ambiguë
 - Corpus parallèles
 - → Précis mais peu couvrants
 - Corpus comparables
 - ⇒ Plus couvrants
 - Analyses linguistiques (morpho-syntaxe, syntaxe, sémantique)
 - ⇒ Vérification des constructions (accords, etc.)
- ⇒ Il faut **réordonner** les mots (réagencer les phrases)
 - ▶ Moteurs de traduction
 - Par règles spécifiées par des humains
 - Statistiques à partir des données (corpus)
 - **Hybrides** (combinaison d'approches)

Quelques moteurs en ligne

- ▶ Google Traduction: https://translate.google.fr
- ► Linguee: https://www.linguee.fr
- ► Deepl (Linguee) : https://www.deepl.com/translator
- ► Reverso (Soft.): www.reverso.net/text_translation.aspx
- ► Systran: https://demo-pnmt.systran.net

TP alignement

- Extraction de dictionnaires bilingues
 - Récupérez des textes alignés http://opus.nlpl.eu/OpenSubtitles
 - Écrire un programme pyton qui
 - Ouvre le fichier de données
 - Recherche les correspondances entre mots alignés
 - Recherche tous les correspondances entre mots
 - Affiche les correspondances fréquentes
 - Appliquez ce programme à http://www.statmt.org/europarl/

Plan

- Automatiser la traduction
- 2. Traduction automatique
- 3. Traduction assistée

Approches

- ► Traduction automatique
 - Post-édition (correction)
 - ⇒ Quelle efficacité, quels biais de traduction?
- ▶ Mémoires de traduction
 - Assistants de rédaction pour la traduction
 - Plus ou moins **personnalisés** / **mutualisés**
 - Approche par **segments** (séquences de mots)
 - Contrôle de la cohérence des traductions
 - ⇒ Logiciels professionnels (SDL Trados)